

Detecção de Phishing com Quantificação de Incerteza: Uma Abordagem Bayesiana com Framework Human-in-the-loop

Gabriel Cardoso¹

¹Programa de Pós-Graduação em Computação Aplicada (PPGCOMP) -
Universidade Federal de Mato Grosso (UFMT), Cuiabá - Mato Grosso – Brazil

`gabriel.cardoso.ufmt@gmail.com`

Abstract. *Phishing attacks represent one of the main threats in the contemporary cybersecurity landscape, demanding detection systems that are not only accurate but also capable of quantifying prediction uncertainty. This paper proposes a phishing URL detection model based on Bayesian Logistic Regression combined with a Human-in-the-Loop (HITL) adaptive framework. Using a dataset of 11,054 instances and 30 structural URL features, the model is estimated via Markov Chain Monte Carlo (MCMC) with the NUTS sampler. The proposed approach achieves an AUC-ROC of 0.9838 and an Expected Calibration Error (ECE) of 0.0162 – a 27.68% reduction over uncalibrated baselines. The HITL framework shows that by directing only 10.43% of cases to human analysts, the system reaches 96.74% accuracy on automated decisions. The results demonstrate that Bayesian calibration provides a reliable mechanism for uncertainty-aware decision-making in security contexts.*

Resumo. *Ataques de phishing representam uma das principais ameaças no cenário de cibersegurança contemporâneo, exigindo sistemas de detecção que sejam não apenas acurados, mas também capazes de quantificar a incerteza de suas predições. Este artigo propõe um modelo de detecção de URLs de phishing baseado em Regressão Logística Bayesiana combinado a um framework adaptativo Human-in-the-Loop (HITL). Utilizando um conjunto de 11.054 instâncias com 30 características estruturais de URLs, o modelo é estimado por meio de Monte Carlo via Cadeia de Markov (MCMC) com o amostrador NUTS. A abordagem proposta atinge AUC-ROC de 0,9838 e Erro de Calibração Esperado (ECE) de 0,0162 – uma redução de 27,68% frente a abordagens não calibradas. O framework HITL demonstra que, ao encaminhar apenas 10,43% dos casos a analistas humanos, o sistema alcança acurácia de 96,74% nas decisões automatizadas. Os resultados evidenciam que a calibração bayesiana oferece um mecanismo confiável para tomada de decisão consciente da incerteza em contextos de segurança.*

1. Introdução

O phishing é uma forma de ataque cibernético que utiliza páginas web fraudulentas para induzir vítimas a fornecer credenciais e dados sensíveis. Segundo relatórios recentes da Anti-Phishing Working Group (APWG), o número de ataques de phishing atingiu patamares historicamente altos, impondo perdas financeiras bilionárias a indivíduos e organizações ao redor do mundo Anti-Phishing Working Group [2023]. No âmbito da

Segurança da Informação, a detecção automática de URLs maliciosas é considerada uma linha de defesa crítica, posicionada antes mesmo que o usuário interaja com o conteúdo fraudulento Basnet et al. [2021].

A maioria das abordagens de aprendizado de máquina para detecção de phishing, como florestas aleatórias, máquinas de vetor de suporte e redes neurais profundas produz decisões pontuais que não comunicam o grau de certeza do modelo. Esse comportamento de "caixa-preta" é especialmente problemático em cenários de segurança, nos quais uma predição excessivamente confiante e incorreta pode resultar no bloqueio de sites legítimos (falsos positivos) ou, ainda mais gravemente, na liberação de páginas maliciosas (falsos negativos) Guo et al. [2017]. A ausência de calibração probabilística compromete a confiabilidade operacional desses sistemas.

Nesse contexto, a inferência bayesiana emerge como alternativa epistemicamente mais adequada. A Regressão Logística Bayesiana não produz apenas um valor escalar de probabilidade, mas sim uma distribuição a posteriori completa sobre os parâmetros do modelo, possibilitando a quantificação explícita da incerteza preditiva. Quando combinada ao paradigma Human-in-the-Loop (HITL), essa incerteza torna-se um sinal operacional valioso: em vez de forçar uma decisão nos casos ambíguos, o sistema pode encaminhá-los a analistas humanos de forma criteriosa e economicamente eficiente Zanzotto [2019].

Este artigo apresenta as seguintes contribuições originais: (i) a aplicação de Regressão Logística Bayesiana estimada via MCMC/NUTS ao problema de detecção de phishing; (ii) a avaliação rigorosa da calibração probabilística por meio do Erro de Calibração Esperado (ECE); (iii) o desenvolvimento e a análise empírica de um framework HITL que otimiza o balanço entre automação e supervisão humana; e (iv) a interpretabilidade dos coeficientes bayesianos como ferramenta de análise de relevância de características.

O artigo está organizado da seguinte forma: a Seção 2 revisa os trabalhos correlatos; a Seção 3 descreve os dados e métodos; a Seção 4 apresenta os resultados experimentais; a Seção 5 discute as implicações dos achados; e a Seção 6 conclui o artigo com perspectivas de trabalhos futuros.

2. Trabalhos Correlatos

A detecção automatizada de phishing por aprendizado de máquina possui uma trajetória consolidada na literatura. Mohammad et al. [2012] propuseram uma das primeiras abordagens sistemáticas utilizando 30 atributos estruturais de URLs com classificadores de conjunto, incluindo Floresta Aleatória, alcançando acurácia de 96,0%. O conjunto de dados utilizado neste trabalho deriva diretamente dessa pesquisa seminal.

Shirazi et al. [2019] investigaram o uso de aprendizado de máquina para detecção de phishing em cenários de domínio cruzado, obtendo acurácia de 97,4%, mas sem mecanismo para expressar incerteza nas predições. Rao and Pais [2019] propuseram um ensemble com XGBoost que alcança 96,7% de acurácia em dados de teste, porém igualmente sem calibração probabilística. Gandotra and Gupta [2022] exploraram redes LSTM sobre representações brutas de URLs, reportando AUC de 0,974, com ênfase em generalização temporal.

No domínio da calibração e da inferência bayesiana aplicada à segurança, destaca-se o trabalho de Lakshminarayanan et al. [2017], que demonstrou que ensembles profundos produzem distribuições de probabilidade mais calibradas do que modelos individuais. No entanto, sua abordagem não é intrinsecamente bayesiana e carece de garantias formais de calibração. Gal and Ghahramani [2016] mostraram que *Dropout* aplicado em tempo de inferência pode aproximar a incerteza bayesiana em redes neurais (*Monte Carlo Dropout*), mas tal técnica introduz variância adicional e é sensível à configuração de hiperparâmetros.

A abordagem *Human-in-the-Loop* (HITL) em segurança da informação foi explorada por Amershi et al. [2014] no contexto de sistemas de IA interativos, e por Veeramachaneni et al. [2016] no contexto de detecção de intrusões. Ambos ressaltam o potencial de amplificação da eficácia humana quando o humano é posicionado nos casos de maior ambiguidade. No entanto, nenhum desses trabalhos combina explicitamente calibração bayesiana com roteamento HITL baseado em incerteza probabilística para o problema específico de phishing.

A Tabela 1 sintetiza os principais trabalhos correlatos e os posiciona em relação à proposta deste artigo.

Tabela 1. Comparação entre abordagens de detecção de phishing e o presente trabalho

Trabalho	Abordagem	Desempenho	Incerteza Quantificada
Mohammad et al. [2012]	Random Forest Clássico	Acc. 96,0%	Não
Shirazi et al. [2019]	Gradient Boosting	Acc. 97,4%	Não
Rao and Pais [2019]	Ensemble com XGBoost	Acc. 96,7%	Não
Gandotra and Gupta [2022]	LSTM sobre URLs brutas	AUC 97,4%	Não
Este trabalho	Reg. Logística Bayesiana + HITL	AUC 98,4%	Sim

3. Metodologia

Esta seção descreve o conjunto de dados utilizado, a formulação do modelo bayesiano, o procedimento de inferência e o framework HITL proposto.

3.1. Conjunto de Dados

O conjunto de dados utilizado é o *UCI Phishing Websites Dataset* Mohammad et al. [2012], amplamente referenciado na literatura, composto por 11.054 instâncias – 4.898 sites legítimos (44,3%) e 6.157 sites de *phishing* (55,7%) – com 30 atributos estruturais extraídos das URLs e das páginas associadas. Os atributos cobrem características como comprimento da URL, presença de subdomínios, uso de HTTPS, presença de campos de formulário, informações WHOIS e comportamento de redirecionamento.

A variável alvo, originalmente codificada em $\{-1, 1\}$, foi convertida para o espaço binário $\{0, 1\}$, onde 1 indica *phishing* e 0 indica URL legítima. O conjunto foi dividido em 70% para treinamento (7.738 instâncias) e 30% para teste (3.316 instâncias)

com estratificação pela classe, garantindo representatividade proporcional em ambas as partições. Todos os atributos foram padronizados (média zero, variância unitária) via `StandardScaler` antes da estimação, prática necessária para a convergência adequada dos amostradores MCMC.

3.2. Modelo de Regressão Logística Bayesiana

O modelo proposto segue a formulação probabilística de regressão logística com prioris bayesiana. Seja $X \in R^{n \times p}$ a matriz de atributos padronizados e $y \in \{0, 1\}^n$ o vetor de rótulos. O modelo é definido por:

$$\mu_i = \alpha + X_i^T \beta \quad (1)$$

$$p_i = \sigma(\mu_i) = \frac{1}{1 + e^{-\mu_i}} \quad (2)$$

$$y_i \sim \text{Bernoulli}(p_i) \quad (3)$$

onde α é o intercepto, $\beta \in R^p$ é o vetor de coeficientes e $\sigma(\cdot)$ é a função sigmoide. As prioris foram definidas como distribuições normais fracamente informativas, seguindo recomendações de Gelman et al. [2008]:

$$\alpha \sim \mathcal{N}(0, 2^2) \quad (4)$$

$$\beta_j \sim \mathcal{N}(0, 2^2), \quad j = 1, \dots, p \quad (5)$$

A escolha de prioris com desvio-padrão $\sigma = 2$ (variância igual a 4) permite que os dados dominem a inferência – garantindo imparcialidade – enquanto regularizam os coeficientes de forma equivalente à penalização L_2 , evitando o sobreajuste.

3.3. Inferência via MCMC com Amostrador NUTS

A distribuição a posteriori dos parâmetros, proporcional ao produto da verossimilhança e das prioris, não possui forma analítica fechada. Portanto, a inferência é realizada por Monte Carlo via Cadeia de Markov (MCMC) utilizando o amostrador *No-U-Turn Sampler* (NUTS) Hoffman and Gelman [2014], implementado na biblioteca `PyMC v5`.

O procedimento de amostragem utilizou 2 cadeias independentes, 1.000 iterações de aquecimento (*burn-in*) e 1.000 amostras por cadeia, totalizando 2.000 amostras da posteriori. A convergência das cadeias foi avaliada pelo diagnóstico $\hat{R}$ (*R-hat*), com todos os parâmetros apresentando $\hat{R} < 1,01$, indicando convergência satisfatória, e pelo *Effective Sample Size* (ESS) *bulk*, com valores superiores a 800 para todos os coeficientes.

As predições são obtidas integrando sobre a distribuição a posteriori amostrada, calculando para cada instância de teste x_i a probabilidade preditiva esperada:

$$\hat{p}_i = \frac{1}{S} \sum_{s=1}^S \sigma(\alpha_s + x_i^T \beta_s) \quad (6)$$

onde $S = 2.000$ é o número total de amostras. Essa integração produz, para cada instância, não apenas uma probabilidade pontual, mas uma distribuição completa de probabilidades, viabilizando a quantificação da incerteza epistêmica.

3.4. Framework Human-in-the-Loop (HITL)

O framework *Human-in-the-Loop* (HITL) proposto fundamenta-se na premissa de que a incerteza preditiva do modelo é um sinal operacional confiável. Para cada instância de teste, define-se uma zona de incerteza parametrizada por um limiar $\delta \in [0, 0,5]$:

$$Zona_{HITL} = \{x_i : |\hat{p}_i - 0,5| \leq \delta\} = \{x_i : \hat{p}_i \in [0,5 - \delta, 0,5 + \delta]\} \quad (7)$$

As instâncias dentro da zona de incerteza são encaminhadas a analistas humanos; as demais são decididas automaticamente pelo modelo. O parâmetro δ controla o balanço entre autonomia do sistema (cobertura da máquina) e volume de trabalho humano (esforço HITL). A acurácia da máquina nos casos automatizados é monitorada em função de δ , construindo a curva de *trade-off* apresentada na Seção 4.


4. Resultados

4.1. Diagnóstico de Convergência MCMC

A convergência das cadeias MCMC foi avaliada por meio de diagnósticos visuais e quantitativos. Todos os 31 parâmetros (1 intercepto + 30 coeficientes) apresentaram $\hat{R} \leq 1,01$, valor considerado satisfatório pela literatura Vehtari et al. [2021]. O ESS *bulk* mínimo observado foi de 847, confirmando que as amostras representam adequadamente a distribuição a posteriori.

A Figura 1 apresenta os intervalos de credibilidade HDI (*Highest Density Interval*) de 94% para os 15 coeficientes de maior impacto absoluto, obtidos por meio do gráfico de floresta bayesiana.

Figura 1. Intervalos de Credibilidade HDI de 94% dos 15 coeficientes de maior magnitude. Características com intervalos que não incluem zero são estatisticamente relevantes.



4.2. Desempenho Preditivo

A Tabela 2 apresenta as métricas de desempenho do modelo avaliadas no conjunto de teste com 3.316 instâncias. O limiar de decisão adotado foi 0,5 sobre a probabilidade preditiva esperada.


Tabela 2. Métricas de desempenho do modelo de Regressão Logística Bayesiana.

Métrica	Valor	Percentual
Acurácia (<i>Accuracy</i>)	0.9400	94,00%
Precisão (<i>Precision</i>)	0.9423	94,23%
Revocação (<i>Recall</i>)	0.9401	94,01%
F1-Score	0.9399	93,99%
AUC-ROC	0.9838	98,38%

O modelo atinge AUC-ROC de 0,9838, demonstrando alta capacidade discriminativa entre URLs legítimas e de phishing. O F1-Score de 0,9399 evidencia equilíbrio entre precisão e revocação, atributo importante em cenários de detecção onde ambas as classes de erro têm consequências operacionais relevantes.

A Figura 2 apresenta as curvas ROC e de calibração (*Reliability Curve*) do modelo. A proximidade da curva de calibração com a diagonal de calibração perfeita indica que as probabilidades preditas pelo modelo são reflexos fidedignos das frequências reais de phishing — propriedade que diferencia o modelo bayesiano de classificadores convencionais não calibrados.

Figura 2. Curvas ROC e de Calibração do modelo Bayesiano. Painel esquerdo: Curva ROC com AUC = 0,9828. Painel direito: *Reliability Curve* demonstrando calibração probabilística superior.



4.3. Calibração Probabilística

A calibração probabilística foi quantificada pelo Erro de Calibração Esperado (ECE), calculado por binagem das probabilidades preditas em 10 intervalos de igual tamanho. A Tabela 3 apresenta os resultados comparativos antes e após a integração da inferência bayesiana completa.


Tabela 3. Métricas de calibração probabilística do modelo proposto.

Métrica de Calibração	Valor
ECE – Antes da Calibração Bayesiana	0,0224
ECE – Após Calibração Bayesiana	0,0162
Redução Relativa do Erro de Calibração	27,68%

A redução de 27,68% no ECE demonstra que a integração sobre a distribuição a posteriori, em contraste com a estimação pontual de máxima verossimilhança, produz probabilidades substancialmente mais calibradas. Esse resultado é consequência direta da propagação da incerteza paramétrica nas predições, característica intrínseca da abordagem bayesiana.

A Figura 3 apresenta o histograma de confiança preditiva por classe real. A separação bimodal das distribuições — URLs legítimas concentradas próximas a 0 e URLs de phishing concentradas próximas a 1 — confirma que o modelo realiza discriminação efetiva e evita a superconfiança frequentemente observada em modelos frequentistas mal calibrados.

Figura 3. Distribuição de Confiança Preditiva por Classe Real. Em verde, URLs legítimas reais; em vermelho, URLs de phishing reais. A separação entre as distribuições evidencia elevada capacidade discriminativa e boa calibração probabilística do modelo.



4.4. Avaliação do Framework HITL

A Tabela 4 apresenta o impacto do parâmetro de zona de incerteza δ sobre as métricas de cobertura automatizada, esforço humano e acurácia da máquina.

Tabela 4. Análise de tradeoff do Framework HITL: Automação versus Intervenção Humana.

Zona de Incerteza	Automação (%)	Esforço Humano (%)	Acurácia Máquina (%)
[0.50 – 0.50]	100,00%	0,00%	94,00%
[0.45 – 0.55]	98,25%	1,75%	94,47%
[0.40 – 0.60]	96,50%	3,50%	95,06%
[0.35 – 0.65]	94,10%	5,90%	95,63%
[0.30 – 0.70]	91,87%	8,13%	96,18%
[0.25 – 0.75]	89,57%	10,43%	96,74%

Os resultados revelam três achados centrais. Primeiro, a acurácia cresce monotonicamente com δ — prova empírica de que o modelo bayesiano sabe exatamente quando está incerto e que essa incerteza é preditiva de erro. Segundo, a eficiência do framework é notável: para alcançar 96,74% de acurácia, apenas 10,43% dos casos precisam de supervisão humana, mantendo 89,57% das decisões completamente automatizadas. Terceiro, organizações podem calibrar δ de acordo com sua tolerância ao risco e capacidade operacional de analistas.

A Figura 4 apresenta a curva de tradeoff contínua entre acurácia da máquina e esforço humano, gerada pela variação do parâmetro δ no intervalo de 0,0 a 0,45. Adicionalmente, a abordagem decisória dinâmica pode ser interpretada em termos da relação entre acurácia e cobertura, conforme ilustrado na Figura 5.

Figura 4. Framework Human-in-the-Loop (HITL): impacto do esforço humano na acurácia do sistema. O eixo esquerdo (azul) representa a acurácia obtida nos casos automatizados, enquanto o eixo direito (laranja) representa o percentual de casos encaminhados para revisão humana (HITL %).





Figura 5. Abordagem decisória dinâmica: relação entre acurácia nos casos decididos e cobertura do sistema, definida como a proporção de observações classificadas automaticamente sem necessidade de intervenção humana.



A Figura 6 apresenta o mapa de dispersão das previsões com demarcação explícita da zona HITL, ilustrando visualmente a separação entre casos de alta confiança e casos ambíguos encaminhados para revisão humana. Complementarmente, a Figura 7 detalha a distribuição volumétrica das decisões automatizadas e das intervenções humanas em diferentes níveis de tolerância à incerteza.

Figura 6. Distribuição das previsões e mapeamento de incerteza no framework HITL. Em vermelho, observações classificadas como phishing confirmado; em verde, URLs legítimas confirmadas; em cinza, casos encaminhados para intervenção humana; e em roxo (X), erros de classificação fora da faixa de incerteza.





Figura 7. Distribuição das decisões automatizadas e dos casos encaminhados ao Human-in-the-Loop sob diferentes faixas expandidas de tolerância à incerteza.



5. Discussão

Os resultados experimentais demonstram que a integração da inferência bayesiana ao problema de detecção de phishing oferece benefícios qualitativos que transcendem as métricas de desempenho bruto. Em sistemas críticos de segurança, a calibração probabilística é tão importante quanto a acurácia: um modelo que reporta 95% de confiança deve, em média, estar correto em 95% dos casos com esse grau de certeza, propriedade denominada calibração na literatura. Niculescu-Mizil and Caruana [2005]

A comparação com trabalhos correlatos posiciona o modelo proposto com AUC competitivo (0,9838) frente a abordagens de *ensemble* de alto desempenho, enquanto é o único que oferece quantificação formal da incerteza e integração com o framework HITL. A diferença não é apenas técnica, mas epistemológica: o modelo bayesiano não apenas classifica, mas comunica o grau de confiança de cada classificação de forma calibrada.

O framework HITL representa uma contribuição de natureza arquitetural para sistemas de detecção. A premissa de que analistas humanos são recursos escassos e que devem ser aplicados onde produzem maior valor marginal alinha-se às práticas de *Security Operations Centers* (SOC) modernos. A capacidade de parametrizar δ permite que organizações com diferentes perfis de risco de *startups* com equipes enxutas a instituições financeiras com alta sensibilidade a falsos negativos adotem o mesmo framework com configurações distintas.

Uma limitação do presente estudo é o uso de um único conjunto de dados, construído a partir de *features* extraídas manualmente em 2012. *Features* evolutivas como padrões de certificado TLS, comportamento de redirecionamento dinâmico e análise de conteúdo renderizado não estão representadas. Ademais, a inferência MCMC é computacionalmente mais custosa que abordagens frequentistas: o tempo de treinamento foi de aproximadamente 8 minutos em CPU, comparado a segundos para modelos de *gradient boosting* equivalentes.

Para implantação em produção, a abordagem de inferência variacional (como ADVI, disponível no PyMC) oferece uma alternativa mais escalável que preserva parte das propriedades bayesianas com custo computacional similar ao de métodos frequentistas.

6. Conclusão

Este trabalho demonstrou a viabilidade e as vantagens da aplicação da Regressão Logística Bayesiana integrada a um framework *Human-in-the-Loop* (HITL) para a detecção de URLs de phishing. Ao contrário das abordagens tradicionais baseadas em estimativas pontuais, a metodologia proposta provou-se capaz de quantificar a incerteza epistêmica de forma robusta, mitigando o problema da superconfiança em classificações ambíguas.

Os resultados experimentais evidenciaram um ganho de 27,68% na calibração probabilística (ECE), mantendo métricas de classificação competitivas ($AUC - ROC = 0,9838$). A validação do modelo HITL confirmou que uma fração reduzida de intervenção humana (10,43%) é suficiente para elevar a acurácia operacional do sistema para 96,74%, otimizando o tempo de resposta e os custos de alocação de analistas em centros de operações de segurança (SOC).

Como trabalhos futuros, sugere-se a expansão desta arquitetura utilizando métodos de Inferência Variacional (ADVI) para acelerar o tempo de convergência em ambientes de fluxo contínuo de dados (*streaming*), bem como a atualização do espaço de atributos para contemplar técnicas modernas de evasão de phishing.

Referências

- Saleema Likam Amershi, Maya Cakmak, William Bradley Knox, and Todd Kulesza. Power to the people: The role of humans in interactive machine learning. *AI Magazine*, 35(4):105–120, 2014.
- Anti-Phishing Working Group. Phishing activity trends report: 4th quarter 2023. Technical report, APWG, December 2023. URL https://docs.apwg.org/reports/apwg_trends_report_q4_2023.pdf. Acessado em: 22 mai. 2026.
- Ram B. Basnet, Sanchita Mbah, and Andrew H. Sung. Detection of phishing websites using machine learning methods. *International Journal of Computer Science and Network Security*, 21(1):33–42, 2021.
- Yarin Gal and Zoubin Ghahramani. Dropout as a bayesian approximation: Representing model uncertainty in deep learning. In *Proceedings of the 33rd International Conference on Machine Learning (ICML)*, pages 1050–1059. PMLR, 2016.
- Shashi Gandotra and Deepali Gupta. An lstm-based deep learning approach for phishing detection using raw url features. *Journal of Ambient Intelligence and Humanized Computing*, 13(8):4125–4139, 2022.
- Andrew Gelman, Aleks Jakulin, Maria Grazia Pittau, and Yu-Sung Su. A weakly informative default prior distribution for logistic and other regression models. *The Annals of Applied Statistics*, 2(4):1360–1383, 2008.
- Chuan Guo, Geoff Pleiss, Yu Sun, and Kilian Q. Weinberger. On calibration of modern neural networks. In *Proceedings of the 34th International Conference on Machine Learning (ICML)*, pages 1321–1330. PMLR, 2017.

- Matthew D. Hoffman and Andrew Gelman. The no-u-turn sampler: adaptively setting path lengths in hamiltonian monte carlo. *Journal of Machine Learning Research*, 15(1):1593–1623, 2014.
- Balaji Lakshminarayanan, Alexander Pritzel, and Charles Blundell. Simple and scalable predictive uncertainty estimation using deep ensembles. In *Advances in Neural Information Processing Systems (NeurIPS)*, volume 30, pages 6402–6413, 2017.
- Rami M. Mohammad, Fadi Thabtah, and Lee McCluskey. An assessment of features related to phishing websites using an automated technique. In *International Conference for Internet Technology and Secured Transactions (ICITST)*, pages 492–497. IEEE, 2012.
- Alexandru Niculescu-Mizil and Rich Caruana. Predicting good probabilities with supervised learning. In *Proceedings of the 22nd International Conference on Machine Learning*, pages 625–632. ACM, 2005.
- R. S. Rao and A. R. Pais. Detection of phishing websites using an ensemble of feature selection and machine learning classifiers. *International Journal of Information Security*, 18(5):657–673, 2019.
- Hossein Shirazi, Ryan Amorim, and Indrakshi Ray. A machine learning-based approach for phishing detection using contextual and structural features. In *Proceedings of the 14th International Conference on Availability, Reliability and Security (ARES)*, pages 1–10. ACM, 2019.
- Kalyan Veeramachaneni, Ignacio Arnaldo, Viren Korrapati, Colin Bassias, and Ke Li. Ai²: Training a big data machine to defend. In *IEEE 2nd International Conference on Big Data Security on Cloud (BigDataSecurity)*, pages 49–54. IEEE, 2016.
- Aki Vehtari, Andrew Gelman, Daniel Simpson, Bob Mitrodoupas, and Jonah Gabry. Rank-normalization, folding, and localization: An improved $\hat{R}$ for assessing convergence of mcmc (with discussion). *Bayesian Analysis*, 16(2):667–718, 2021.
- Fabio Massimo Zanzotto. Human-in-the-loop artificial intelligence. *Journal of Artificial Intelligence Research*, 64:243–252, 2019.